

ApakanDuluApaltuBiarGaApaKali

PROPOSAL TEKNIS: THE PRIVACY BRAIN

Pengembangan Small Language Model (SLM) untuk Deteksi Hoax Berbasis Offline dan Privasi Data

CkCk

Privacy-Aware Hoax Detection AI

Disusun oleh:

Bram Sebastian Pangaribuan

Hakam Avicena

Richard Samuel

Natanael Manurung

Rava Saragih (Ketua)

TIM ApakanDuluApaltuBiarGaApaKali

DAFTAR ISI

DAFTAR ISI	2
BAB I PENDAHULUAN	3
1.1. Latar Belakang	3
1.2. Identifikasi Masalah	4
1.3. Tujuan	4
BAB II METODOLOGI AI	6
2.1. Dataset	6
2.1.1. Sumber Data	6
2.1.2. Karakteristik Dataset	6
2.1.3. Lisensi dan Etika Penggunaan	8
2.2. Arsitektur	9
2.2.1. Komponen Pipeline	9
2.2.2. Empat Status Output	10
2.2.3. Model Utama: IndoBERT Classifier	10
2.2.4. Komponen Pendukung: Rule-based Detector	11
2.3. Preprocessing	11
2.4. Evaluasi	12
2.4.1. Strategi Pembagian Data	12
2.4.2. Metrik Evaluasi	12
2.4.3. Target Performa	13
BAB III KEPATUHAN CONSTRAINT	14
3.1. Constraint 1: Model Size ≤ 4 Miliar Parameter	14
3.2. Constraint 2: Offline Total (Zero Network Call)	14
3.3. Constraint 3: PII Filter Wajib	14
3.4. Constraint 4: Cakupan PII	14
3.5. Constraint 5: Fine-tuning Lokal	15
BAB IV RANCANGAN SISTEM DAN BISNIS	16
4.1. Integrasi Phase 3	16
4.1.1 Mode Integrasi yang Direncanakan	17
4.1.2 Rancangan Teknis Phase 3	17
4.2. Analisis Dampak	18
4.2.1. Dampak Sosial	18
4.2.2. Dampak Privasi	18
4.2.3. Dampak Ekonomi dan Ekosistem	18
4.2.4. Mitigasi Resiko	19

BAB I PENDAHULUAN

1.1. Latar Belakang

Indonesia menghadapi krisis disinformasi yang semakin mengancam stabilitas sosial dan keselamatan jiwa. Pada 17 Agustus 2025, sebuah video rekayasa AI yang menampilkan sosok mirip Menteri Keuangan Sri Mulyani menyatakan "guru itu beban negara" ditonton 57.000 kali dan dibagikan 391 kali hanya dalam dua hari sebelum dikonfirmasi sebagai konten AI-generated oleh MAFINDO. Kemarahan publik yang dipicu konten tersebut berkontribusi langsung pada penjarahan fisik kediaman Sri Mulyani di Bintaro pada 31 Agustus 2025.

Pada periode yang sama, video memanipulasi audio Ibu Ana, simbol demonstrasi DPR 28 Agustus 2025, meraih lebih dari 5 juta penayangan di TikTok dan membelah opini publik secara masif sebelum verifikasi menunjukkan suaranya direkayasa oleh teknologi AI. Kedua peristiwa ini bukan anomali, melainkan bukti bahwa disinformasi AI-generated telah berevolusi dari ancaman informasi menjadi ancaman keselamatan jiwa yang nyata.

Kesamaan dari kedua kasus tersebut adalah bersumber dari video yang sudah menjadi hiburan utama masyarakat Indonesia, terutama video pendek. Format ini bukan kebetulan dipilih oleh pelaku disinformasi. Video pendek dirancang untuk dikonsumsi dalam hitungan detik, diproses secara emosional sebelum sempat dipikirkan secara kritis, dan disebar dengan satu ketukan jari sebelum otak sempat bertanya: apakah ini benar? Inilah yang membuat disinformasi berbasis video pendek begitu mematikan bukan karena kontennya canggih, tetapi karena mekanisme penyebarannya mengeksploitasi kebiasaan konsumsi digital yang sudah tertanam dalam kehidupan sehari-hari masyarakat Indonesia.

Wakil Menteri Komdigi mencatat konten deepfake meningkat 550 persen dalam lima tahun terakhir, sementara Komdigi mengidentifikasi 1.923 isu hoaks sepanjang 2024. Dengan indeks literasi digital nasional hanya 49,28 dari skala 100 dan penetrasi media sosial yang terus meningkat, Indonesia berada di titik kritis rentan destabilisasi sosial berbasis disinformasi teknologi berskala besar.

Akar persoalan terletak pada celah teknologi yang belum terselesaikan. Keputusan untuk mempercayai dan menyebarkan sebuah konten terjadi

bukan setelah menonton secara kritis, melainkan pada detik pertama saat mata menangkap teks yang tertanam di dalam frame visual overlay grafis, ticker berita palsu, logo media yang dipalsukan maupun caption yang menyertai konten di platform media sosial. Tidak ada sistem yang mampu menganalisis kedua lapisan teks tersebut secara otomatis, memberikan peringatan dini sebelum tombol bagikan ditekan, sekaligus beroperasi sepenuhnya tanpa ketergantungan pada server asing.

1.2. Identifikasi Masalah

Berdasarkan latar belakang yang telah diuraikan, CkCk merumuskan tiga permasalahan utama yang menjadi fokus solusi:

- Bagaimana membangun sistem deteksi hoaks yang mampu memproses konten berbahasa Indonesia secara akurat, dengan mempertimbangkan karakteristik linguistik lokal seperti penggunaan urgensi palsu, fear-mongering, dan atribusi tidak valid kepada tokoh publik?
- Bagaimana memastikan privasi pengguna tetap terlindungi dalam proses analisis konten, termasuk melindungi Informasi Identifikasi Pribadi (PII) yang mungkin terkandung dalam teks yang dianalisis?
- Bagaimana menyajikan hasil analisis dalam format yang transparan dan dapat dipahami pengguna awam, sehingga meningkatkan literasi digital dan kemampuan kritis masyarakat terhadap konten yang mereka terima?

1.3. Tujuan

CkCk bertujuan untuk mewujudkan tiga sasaran utama berikut:

1. Membangun pipeline deteksi hoaks end-to-end yang beroperasi sepenuhnya secara offline, menggunakan model IndoBERT yang di-fine-tune khusus pada dataset hoaks Indonesia, untuk mengklasifikasikan konten menjadi empat kategori status yang informatif dan dapat ditindaklanjuti.
2. Mengimplementasikan lapisan perlindungan privasi berlapis yang mencakup penyaringan PII wajib (NIK, nomor telepon, email, nomor rekening) sebelum data masuk ke komponen analisis apapun, memastikan tidak ada informasi sensitif pengguna yang terekspos.
3. Menghasilkan penjelasan analisis berbahasa Indonesia yang jelas dan actionable, yang tidak hanya memberikan verdict (terverifikasi/hoaks) tetapi juga menjelaskan pola linguistik spesifik yang menjadi dasar

keputusan, sehingga meningkatkan kepercayaan dan literasi digital pengguna.

BAB II METODOLOGI AI

2.1. Dataset

CkCk menggunakan dataset yang bersumber dari repositori cek fakta terkemuka di Indonesia, beserta dengan 3 situs berita Indonesia yang dikombinasikan dan diproses untuk keperluan fine-tuning model.

2.1.1. Sumber Data

Dataset yang digunakan dalam penelitian ini merupakan dataset berita hoaks yang dikembangkan oleh Mochamad Abdul Azis. Datanya dikumpulkan melalui proses web scraping dari empat sumber berita Indonesia yaitu :

1. TurnBackHoax.id
2. Antaranews
3. Kompas
4. Detik

2.1.2. Karakteristik Dataset

Dataset disimpan dalam format .csv dengan bahasa penulisan Bahasa Indonesia. Rincian jumlah entri per sumber dapat dilihat pada Tabel berikut.

No.	Sumber	Kategori	Jumlah Entri
1	TurnBackHoax.id	Hoaks	12744
2	AntaraNews	Berita Valid	4200
3	Kompas	Berita Valid	3500

4	Detik	Berita Valid	3498
Total			23942

Table 2.1 Dataset AI Training

Dataset ini bersifat tidak seimbang (imbalanced), dengan kelas hoaks mendominasi sekitar 53,2% dari total data, sementara kelas berita valid mencakup 46,8%. Kondisi ini perlu diperhatikan dalam tahap pra-pemrosesan data dan pemilihan metrik evaluasi model.

Nama	Data Type	Penjelasan
url	String (Link)	Berisi tautan atau alamat web dari sumber berita asli. URL digunakan untuk mengidentifikasi sumber artikel serta dapat membantu dalam proses verifikasi atau pelacakan asal informasi. Namun, kolom ini tidak digunakan dalam proses training model karena tidak mengandung informasi tekstual yang relevan untuk klasifikasi isi berita.
judul	string	Berisi judul dari artikel berita, judul biasanya merupakan ringkasan singkat yang mencerminkan inti dari isi berita dan sering kali mengandung kata kunci penting yang relevan untuk menentukan apakah suatu berita termasuk hoaks atau valid.
narasi	string	berisi isi lengkap atau body dari artikel berita. Narasi memberikan konteks yang lebih detail dan mendalam mengenai informasi yang disampaikan, sehingga sangat penting untuk

		memahami keseluruhan makna dan mendeteksi pola hoaks.
label	integer	Berisi target klasifikasi dari setiap data, yaitu: 0 = berita valid 1 = berita hoaks Kolom ini digunakan sebagai ground truth dalam proses training dan evaluasi model.
clean_text	string	Berisi versi yang telah diproses (cleaned) dari teks berita, patokan utamanya dari narasi. Proses pembersihan meliputi penghapusan karakter tidak penting, normalisasi huruf (misalnya menjadi lowercase), serta penghilangan noise seperti URL atau simbol tertentu. Tujuannya adalah untuk menghasilkan teks yang lebih konsisten dan mudah diproses oleh model.

Table 2.2 Penjelasan atribut pada dataset

Fitur yang digunakan dalam proses training adalah **judul dan clean_text sebagai input**, serta **label sebagai target**. Kolom *clean_text* dipilih karena sudah melalui proses pembersihan sehingga lebih konsisten dan minim noise, sedangkan *judul* ditambahkan karena mengandung informasi inti yang dapat membantu model memahami konteks berita dengan lebih cepat. Kedua kolom tersebut digabung untuk meningkatkan performa klasifikasi. Sementara itu, kolom *label* digunakan sebagai acuan dalam supervised learning. Kolom *url* tidak digunakan karena tidak memiliki informasi semantik yang relevan, dan *narasi* tidak dipakai secara langsung karena masih mengandung noise serta belum melalui preprocessing yang sesuai dengan pipeline saat ini.

2.1.3. Lisensi dan Etika Penggunaan

Dataset ini dilisensikan untuk keperluan riset dan perlombaan dengan ketentuan:

- Seluruh hak cipta konten berita tetap berada pada masing-masing pemilik sumber asli.

- Penggunaan atau distribusi ulang untuk tujuan komersial tidak diizinkan.
- Penggunaan dataset ini wajib menyertakan atribusi kepada sumber berita asli (Antarnews, Kompas, Detik, dan TurnBackHoax.id) serta pembuat dataset.

Sesuai ketentuan tersebut, penggunaan dataset dalam penelitian ini semata-mata ditujukan untuk keperluan akademik dan pengembangan sistem deteksi berita hoaks secara non-komersial.

2.2. Arsitektur

CkCk mengimplementasikan arsitektur pipeline sequential dengan empat komponen utama yang beroperasi dalam urutan yang deterministik. Setiap komponen memiliki tanggung jawab yang terdefinisi dengan jelas, mencegah tumpang tindih fungsi dan memastikan auditabilitas sistem.

2.2.1. Komponen Pipeline

Tahap	Komponen	Fungsi	Urutan Eksekusi
1	OCR Engine	Ekstraksi teks dari gambar/frame video menggunakan pytesseract / EasyOCR. Fallback otomatis ke caption jika hasil OCR < 15 karakter.	Pertama (jika input = gambar)
2	PII Filter	Sensor regex untuk NIK (16 digit), telepon (+62xx/08xx), email, dan rekening. Selalu berjalan sebelum komponen AI apapun.	Kedua (wajib, tanpa pengecualian)
3	IndoBERT Classifier	Model sequence classification fine-tuned pada dataset MAFINDO. Penentu keputusan utama (100%). Output: confidence score hoaks vs valid.	Ketiga

4	Rule-based Detector	Deteksi pola linguistik manipulatif (urgensi palsu, fear-mongering, atribusi invalid). TIDAK mengubah skor — hanya memperkaya penjelasan.	Keempat
5	Output Engine	Menggabungkan confidence score dan pola terdeteksi menjadi salah satu dari 4 status output	Kelima

Table 2.3 Komponen Pipeline

2.2.2. Empat Status Output

Status	Kondisi	Interpretasi
TERVERIFIKASI	Confidence valid $\geq 75\%$	Konten kemungkinan besar akurat dan dapat dipercaya
KONTEKS BERBEDA	Confidence valid 50–75%	Konten mungkin benar namun perlu konfirmasi konteks tambahan
BELUM TERVERIFIKASI — WASPADAI	Confidence hoaks $\geq 50\%$, pola manipulatif terdeteksi	Indikasi kuat sebagai konten manipulatif dengan pola spesifik
BELUM TERVERIFIKASI — NETRAL	Confidence rendah, tidak ada pola manipulatif	Tidak cukup bukti untuk klasifikasi definitif

Table 2.4 Output

2.2.3. Model Utama: IndoBERT Classifier

- Base model: IndoBERT-base-p2 (~110 juta parameter)
- Task: Sequence classification: hoaks (1) vs valid (0)

- Fine-tuning: Dataset MAFINDO/Turnbackhoax.id + IndoNLU benchmark
- Format penyimpanan: .pt (PyTorch) dan ONNX Runtime untuk inferensi CPU-compatible
- Runtime: 100% offline menggunakan local_files_only=True

2.2.4. Komponen Pendukung: Rule-based Detector

Rule-based Detector beroperasi sebagai lapisan transparansi yang menjelaskan 'mengapa' suatu konten mencurigakan, bukan 'apa' hasilnya. Tiga kategori pola yang dideteksi:

- Urgensi palsu: kata/frasa: 'SEGERA', 'VIRAL', 'SEBARKAN', 'JANGAN SAMPAI TERHAPUS'
- Fear-mongering: kata/frasa: 'BAHAYA', 'ANCAMAN', 'KORBAN', 'HANCUR'
- Atribusi invalid: klaim kutipan tokoh publik tanpa sumber yang dapat diverifikasi

2.3. Preprocessing

Pipeline preprocessing CkCk dirancang untuk menangani variasi bahasa Indonesia informal sekaligus mempertahankan signal linguistik yang relevan untuk deteksi hoaks.

- Text cleaning dan normalisasi karakter: penghapusan noise, normalisasi encoding UTF-8
- Normalisasi informal speech: konversi singkatan umum dan slang Indonesia ke bentuk baku
- Tokenisasi: menggunakan tokenizer IndoBERT yang disimpan lokal (folder tokenizer/)
- PII redaction: penggantian PII dengan token placeholder [REDACTED_NIK], [REDACTED_PHONE], dst.
- Truncation dan padding: sesuai dengan maksimum sequence length IndoBERT (512 token)

Pemisahan data train/test dilakukan SEBELUM preprocessing apapun diterapkan, untuk memastikan tidak ada informasi dari test set yang bocor ke proses training melalui statistik normalisasi.

2.4. Evaluasi

Evaluasi model CkCk dilakukan menggunakan stratified holdout split dan metrik klasifikasi standar untuk memastikan keandalan sistem pada data yang belum pernah dilihat selama training.

2.4.1. Strategi Pembagian Data

Dataset gabungan (~23.711 sampel) dibagi secara stratified untuk menjaga distribusi label pada setiap split:

Split	Proporsi	Jumlah Sampel	Fungsi
Training	76,5%	~18.138	Fine-tuning model
Validation	13,5%	~3.201	Early stopping & checkpoint selection
Test	10%	~2.372	Evaluasi akhir (tidak disentuh saat training)

Table 2.5 Pembagian Data

Stratified splitting memastikan rasio hoax:valid (~53%:47%) konsisten di setiap split, mencegah bias evaluasi.

2.4.2. Metrik Evaluasi

Metrik	Definisi	Relevansi (Justifikasi Pemilihan Metrik)
Accuracy	Proporsi prediksi benar dari total sampel	Gambaran umum performa
F1_Score (weighted)	Harmonic mean dari precision dan recall, weighted by class	Metrik utama menyeimbangkan false positive dan false negative

Precision	Dari semua yang diprediksi hoaks, berapa yang benar hoaks	Mengukur risiko false alarm (konten valid ditandai hoaks)
Recall	Dari semua hoaks sebenarnya, berapa yang berhasil terdeteksi	Mengukur risiko hoaks lolos tanpa terdeteksi

Table 2.6 Metrik Evaluasi

Metrik Primer: F1 Score dipilih sebagai metrik primer karena menyeimbangkan precision dan recall penting dalam konteks deteksi hoaks dimana baik false positive (memblokir berita valid) maupun false negative (meloloskan hoaks) sama-sama memiliki dampak sosial.

Checkpoint Selection: Model terbaik disimpan berdasarkan **validation F1 score** tertinggi selama training, bukan berdasarkan training loss, untuk mencegah overfitting.

2.4.3. Target Performa

Metrik	Definisi	Relevansi (Justifikasi Pemilihan Metrik)
Accuracy	> 80%	> 90%
F1_Score (weighted)	> 78%	> 88%
Precision	> 75%	> 85%
Recall	> 80%	> 90%

Table 2.7 Target Performa Model

2.4.4. Evaluasi Hasil

8. Evaluation on Test Set

```
# Evaluate on test set
test_metrics = trainer.evaluate()

if test_metrics:
    print(f"\n📊 Final Test Metrics:")
    print(f"    Accuracy: {test_metrics['accuracy']:.4f}")
    print(f"    F1 Score: {test_metrics['f1']:.4f}")
    print(f"    Precision: {test_metrics['precision']:.4f}")
    print(f"    Recall: {test_metrics['recall']:.4f}")
```

✓ 8.4s

📊 Test Set Classification Report:

	precision	recall	f1-score	support
VALID	0.84	0.86	0.85	1097
HOAX	0.88	0.86	0.87	1275
accuracy			0.86	2372
macro avg	0.86	0.86	0.86	2372
weighted avg	0.86	0.86	0.86	2372

📊 Final Test Metrics:

Accuracy: 0.8579
F1 Score: 0.8580
Precision: 0.8584
Recall: 0.8579

BAB III KEPATUHAN CONSTRAINT

3.1. Constraint 1: Model Size $\leq$ 4 Miliar Parameter

Model The Privacy Brain sepenuhnya mematuhi batasan ukuran parameter yang ditetapkan. Kami memilih menggunakan indobenchmark/indobert-base-p2 sebagai fondasi utama. Secara teknis, model ini hanya memiliki sekitar 110 juta parameter, yang berarti hanya menghabiskan 2,75% dari batas maksimal 4 miliar parameter yang diizinkan. Penggunaan arsitektur Small Language Model (SLM) ini memastikan bahwa sistem tidak hanya ringan, tetapi juga memiliki kecepatan inferensi yang tinggi meskipun hanya dijalankan menggunakan unit pemrosesan standar (CPU).

3.2. Constraint 2: Offline Total (Zero Network Call)

Kepatuhan terhadap aspek privasi dibuktikan dengan sistem yang beroperasi secara 100% offline. Seluruh bobot model (weights) dan tokenizer telah diunduh dan disimpan secara lokal di dalam direktori proyek. Dalam operasionalnya, inference.ipynb tidak melakukan pemanggilan jaringan (network call) maupun ketergantungan pada API eksternal seperti OpenAI atau layanan cloud lainnya. Hal ini menjamin bahwa data pengguna tidak pernah meninggalkan lingkungan lokal, sehingga meminimalisir risiko kebocoran data di jalur komunikasi internet.

3.3. Constraint 3: PII Filter Wajib

Sistem kami menempatkan keamanan data sebagai prioritas utama melalui integrasi PII Filter yang bekerja secara real-time di dalam pipeline inferensi. Filter ini tidak berdiri sebagai skrip terpisah, melainkan menjadi gerbang utama dalam alur proses data: teks masukan akan dideteksi dan diredaksi terlebih dahulu oleh kelas PIIFilter sebelum diteruskan ke tahap preprocessing dan model. Mekanisme ini memastikan bahwa entitas sensitif sudah disamarkan secara otomatis sebelum model mulai melakukan analisis konten.

3.4. Constraint 4: Cakupan PII

Dalam hal cakupan perlindungan, model ini memenuhi seluruh persyaratan wajib dan memberikan perlindungan tambahan. Sistem secara akurat mampu mengidentifikasi dan meredaksi empat tipe PII utama: NIK (16 digit), Nomor Telepon, Alamat Email, dan Nomor Rekening. Selain itu, kami menyertakan fitur bonus untuk mendeteksi NPWP dan Nomor Paspor.

Validasi menggunakan pola regex yang ketat dan format khusus memastikan bahwa data pribadi dengan konteks Indonesia dapat tertangani dengan tingkat presisi yang tinggi.

3.5. Constraint 5: Fine-tuning Lokal

Model dasar telah melalui proses adaptasi domain melalui Fine-tuning lokal menggunakan dataset yang dikurasi khusus untuk konteks Indonesia. Kami menggabungkan lebih dari 23.000 sampel data dari sumber terpercaya seperti TurnBackHoax.id (MAFINDO), Antara News, Detik, dan Kompas. Proses pelatihan dilakukan secara mandiri dengan menambahkan classification head pada arsitektur IndoBERT, dioptimalkan menggunakan AdamW optimizer, dan dievaluasi ketat menggunakan F1 Score. Hasil akhirnya adalah model yang sangat spesifik dan ahli dalam mendeteksi konten manipulatif atau hoax tanpa harus bergantung pada model raksasa umum.

BAB IV RANCANGAN SISTEM DAN BISNIS

4.1. Integrasi Phase 3

Dalam phase pengembangan lanjutan, CkCk dirancang untuk diintegrasikan sebagai modul yang dapat disematkan (embeddable module) dalam ekosistem platform digital yang lebih luas, sambil mempertahankan prinsip privacy-first yang menjadi keunggulan inti sistem.

4.1.1 Mode Integrasi yang Direncanakan

Mode Integrasi	Target Platform	Mekanisme	Keunggulan
Browser Extension	Chrome, Firefox, Edge	Content script yang menganalisis teks di halaman web secara lokal menggunakan model ONNX yang dikompilasi ke WebAssembly	Zero data transfer sehingga analisis sepenuhnya di device pengguna
Mobile SDK	Android & iOS	Library native yang mengeksport API sederhana: analyze(text) -> CkCkResult. Model ONNX dioptimalkan dengan quantization untuk perangkat mobile	Analisis offline pada smartphone, cocok untuk area dengan koneksi terbatas

Messaging App Plugin	WhatsApp Business API, Telegram Bot	Webhook yang beroperasi pada server on-premise operator, bukan cloud publik. PII Filter tetap berjalan pertama.	Deteksi real-time saat konten diterima tanpa meninggalkan infrastruktur operator
API On-Premise	Platform berita, fact-checker, NGO	REST API yang di-deploy pada server internal klien. Model dan data tidak pernah meninggalkan infrastruktur klien.	Kontrol penuh atas data, cocok untuk organisasi dengan compliance ketat

Table 2.8 Mode Integrasi

4.1.2 Rancangan Teknis Phase 3

Arsitektur CkCk Phase 3 mempertahankan pipeline sequential yang telah terbukti, dengan penambahan lapisan adaptasi untuk multi-platform deployment:

- Model Quantization: konversi model ONNX ke INT8 quantization untuk mengurangi ukuran model hingga 75% tanpa penurunan akurasi yang signifikan, memungkinkan deployment pada perangkat dengan memori terbatas
- Batch Processing API: dukungan analisis multiple teks dalam satu request untuk meningkatkan throughput pada use case bulk verification
- Confidence Threshold Configurability: operator dapat menyesuaikan threshold keempat status output sesuai dengan risk tolerance dan use case spesifik mereka
- Audit Log System: logging deterministik dari setiap keputusan klasifikasi (tanpa menyimpan konten teks) untuk keperluan accountability dan continual improvement
- Federated Learning Support: mekanisme untuk meningkatkan model dari feedback pengguna tanpa mengumpulkan data teks mentah ke server pusat

4.2. Analisis Dampak

4.2.1. Dampak Sosial

CkCk berpotensi memberikan dampak sosial yang signifikan melalui beberapa jalur:

- Peningkatan literasi digital: penjelasan berbahasa Indonesia yang transparan tentang pola manipulatif membantu pengguna memahami mekanisme disinformasi, bukan hanya menerima verdict biner
- Pemberdayaan komunitas rentan: deployment offline memungkinkan penggunaan di komunitas dengan akses internet terbatas yang selama ini paling rentan terhadap hoaks
- Dukungan kapasitas cek fakta: organisasi seperti MAFINDO dapat menggunakan CkCk sebagai triaging tool untuk memprioritaskan verifikasi manual pada konten dengan skor ambiguitas tinggi
- Pengurangan viral seeding: integrasi di level messaging platform dapat memutus rantai penyebaran sebelum konten hoaks mencapai massa kritis.

4.2.2. Dampak Privasi

Seluruh pemrosesan analitik terjadi di device atau server on-premise pengguna. Tidak ada konten teks, metadata, atau pola penggunaan yang dikirimkan ke infrastruktur CkCk. PII yang ditemukan dalam teks disensor sebelum diproses oleh komponen AI manapun. Pengguna memiliki kontrol penuh atas data mereka sepanjang waktu. Model ini secara langsung selaras dengan Undang-Undang Perlindungan Data Pribadi (UU PDP) Indonesia yang mulai diberlakukan penuh, serta regulasi GDPR untuk deployment di pasar Eropa. Kepatuhan regulasi bukan hanya sebagai fitur tambahan, melainkan bagian dari DNA arsitektur sistem.

4.2.3. Dampak Ekonomi dan Ekosistem

Bagi **Platform Media Sosial dan Berita**, nilai utama yang diciptakan adalah efisiensi operasional melalui pengurangan biaya moderasi konten yang dilakukan secara manual. Dengan integrasi model ini, platform dapat secara otomatis menyaring konten berbahaya, yang pada akhirnya meningkatkan kepercayaan (*user trust*) pengguna terhadap ekosistem informasi mereka. Potensi monetisasi di segmen ini dapat dilakukan melalui skema **lisensi SDK**, baik berdasarkan volume jumlah analisis konten maupun jumlah akses.

Dalam ranah **Pemerintah dan Lembaga Negara**, kehadiran model ini memperkuat kapasitas pemantauan disinformasi secara masif dan terukur (*scalable*). Hal ini menjadi instrumen krusial untuk memenuhi bukti kepatuhan terhadap regulasi moderasi konten yang berlaku. Mengingat sifat data yang sensitif, model bisnis yang paling relevan adalah **kontrak layanan on-premise** yang disertai dengan jaminan tingkat layanan atau *Service Level Agreement* (SLA) yang ketat.

Bagi **Pengguna Individual**, nilai yang diciptakan berfokus pada aspek perlindungan diri dari manipulasi informasi serta peningkatan kemampuan berpikir kritis dalam mengevaluasi konten digital. Untuk memastikan jangkauan perlindungan yang luas dan dampak sosial yang maksimal, akses bagi individu disediakan secara **gratis**. Model distribusinya dapat berupa ekstensi peramban (*browser extension*) maupun aplikasi *mobile* yang mudah digunakan untuk memvalidasi informasi dalam aktivitas sehari-hari

4.2.4. Mitigasi Resiko

CkCk mengakui sejumlah keterbatasan yang perlu dimitigasi dalam pengembangan lanjutan:

- Adversarial attacks:
Pelaku disinformasi dapat mempelajari pola yang dideteksi sistem dan menghindarinya. Mitigasi: continuous retraining dengan dataset hoaks terbaru dan eksplorasi adversarial training.
- Domain shift:
Hoaks yang muncul dalam domain baru (misalnya, teknologi deepfake yang terus berkembang) mungkin tidak terdeteksi dengan baik. Mitigasi: pipeline monitoring untuk deteksi distributional shift.
- False positive pada satire dan opini:
Konten satire yang menggunakan pola bahasa urgensi mungkin salah diklasifikasi. Mitigasi: penambahan kategori konteks yang lebih granular dalam output.
- Ketergantungan pada kualitas dataset:

Performa sistem sangat bergantung pada kualitas dan kemutakhiran dataset MAFINDO. Mitigasi: kemitraan aktif dengan komunitas cek fakta untuk pembaruan data berkala.